



**Université du Havre**  
**Faculté des sciences et techniques**

---

**TP : Fouille de données**  
**Régression linéaire simple et multiple (Epuisement des matériaux)**

---

**Réaliser par :**

TOUCHENE Mohamed Amine  
ELMI IBRAHIM Youssouf  
LO Mouhamadou Moustapha

**Enseignant :**

Mr : FOURNIER Dominique

**Master IWOCS**  
**Année universitaire 2017 / 2018**

## Introduction

Le TP a été réalisé en vue de faire une étude sur l'épuisement des matériaux et plus précisément sur l'acier. Au moyen du langage **R** et du fichier **DonneesAcier.csv** donné, nous allons tenter de donner une estimation sur différentes valeurs.

A notre disposition, un échantillon de résultat qui va nous permettre de mesurer les deux principaux coefficients nécessaires pour l'étude de la ductilité des matériaux en question.

$\mathcal{E}'_f$ : Représente le coefficient de ductilité en fatigue ;

$\Sigma'_f$ : Représente le coefficient de résistance en fatigue.

## Résultats et tests

Pour débiter, nous allons faire une lecture du fichier de données **DonneesAcier.csv**.

```
R version 3.2.3 (2015-12-10) -- "Wooden Christmas-Tree"
Copyright (C) 2015 The R Foundation for Statistical Computing
Platform: x86_64-pc-linux-gnu (64-bit)

R est un logiciel libre livré sans AUCUNE GARANTIE.
Vous pouvez le redistribuer sous certaines conditions.
Tapez 'license()' ou 'licence()' pour plus de détails.

R est un projet collaboratif avec de nombreux contributeurs.
Tapez 'contributors()' pour plus d'information et
'citation()' pour la façon de le citer dans les publications.

Tapez 'demo()' pour des démonstrations, 'help()' pour l'aide
en ligne ou 'help.start()' pour obtenir l'aide au format HTML.
Tapez 'q()' pour quitter R.

> projet=read.csv2("donneesAcier.csv")
> projet
  codeAcier numTest   E BHN  RA Sigma_e Sigma_u Epsilon_f Epsilon_prime_f
1      1141      1 216 223  57   457   771    0.84         0.26
2      1141      2 227 277  59   814   925    0.89         0.31
3       220      3 220 199  53   418   695    0.76         0.26
4      1141      4 217 241  54   602   802    0.78         0.36
5      1141      5 214 217  49   450   725    0.67         0.43
6      1141      6 215 252  58   610   797    0.87         0.53
7      1141      7 220 229  47   493   789    0.63         0.60
8      1038      8 201 163  54   331   582    0.78         0.31
9      1038      9 219 185  53   359   652    0.76         0.20
10     1038     10 219 195  67   410   649    1.11         0.23
```

La commande suivante nous donne la matrice de corrélation (notons que les deux premières colonnes sont à omettre, à savoir celles relatives au numéro de test et au code respectivement).

```
> cor(projet[,3:10])
```

	E	BHN	RA	Sigma_e	Sigma_u
E	1.000000000	-0.3518188	0.1427242	-0.4542611	-0.3787762
BHN	-0.351818764	1.0000000	-0.5075624	0.9644053	0.9800446
RA	0.142724190	-0.5075624	1.0000000	-0.4403975	-0.5300379
Sigma_e	-0.454261101	0.9644053	-0.4403975	1.0000000	0.9705248
Sigma_u	-0.378776243	0.9800446	-0.5300379	0.9705248	1.0000000
Epsilon_f	0.125542060	-0.5388124	0.9827108	-0.4655494	-0.5535625
Epsilon_prime_f	0.002866055	-0.1239751	0.1962201	-0.1202111	-0.1631696
Sigma_prime_f	-0.331031610	0.9361995	-0.5472082	0.8964122	0.9463922

  

	Epsilon_f	Epsilon_prime_f	Sigma_prime_f
E	0.1255421	0.002866055	-0.3310316
BHN	-0.5388124	-0.123975139	0.9361995
RA	0.9827108	0.196220131	-0.5472082
Sigma_e	-0.4655494	-0.120211063	0.8964122
Sigma_u	-0.5535625	-0.163169595	0.9463922
Epsilon_f	1.0000000	0.162873180	-0.5660041
Epsilon_prime_f	0.1628732	1.000000000	-0.1259600
Sigma_prime_f	-0.5660041	-0.125959958	1.0000000

## Tests sur $\Sigma'_f$ et $\mathcal{E}'_f$

### Tests sur $\Sigma'_f$

Nous avons les variables qui sont fortement corrélées avec  $\Sigma'_f$ :

$\Sigma_e$ : (0.8964122) ;

$BHN$ : (0.9361995) ;

$\Sigma_u$ : (0.9463922).

```
> mc [,8]
```

	E	BHN	RA	Sigma_e	Sigma_u
	-0.3310316	0.9361995	-0.5472082	0.8964122	0.9463922
	Epsilon_f	Epsilon_prime_f	Sigma_prime_f		
	-0.5660041	-0.1259600	1.0000000		

### Test pour $\Sigma_e$

```
> summary(lm(Sigma_prime_f ~ Sigma_e, projet))
```

Call:  
lm(formula = Sigma\_prime\_f ~ Sigma\_e, data = projet)

Residuals:

	Min	1Q	Median	3Q	Max
	-506.38	-166.25	-40.31	92.53	672.30

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	604.35989	57.97588	10.42	5.84e-16 ***
Sigma_e	0.93085	0.05462	17.04	< 2e-16 ***

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 251.2 on 71 degrees of freedom  
Multiple R-squared: 0.8036, Adjusted R-squared: 0.8008  
F-statistic: 290.4 on 1 and 71 DF, p-value: < 2.2e-16

### Remarque :

Le test est pertinent (\*\*\*) :  
F statistique de 290.4  
p-value :< 2.2e-16  
Moyenne de résidus de 251.2  
r1 de 0.8036  
r2 de 0.8008

En cas de régression multiple, le choix doit être porté sur une variable ayant une faible corrélation avec  $\Sigma_e$  vue que l'ajout d'une variable ayant une forte corrélation avec  $\Sigma_e$  ne va pas provoquer un résultat meilleur.

```
> mc [,4]
      E      BHN      RA      Sigma_e      Sigma_u
-0.4542611  0.9644053 -0.4403975  1.0000000  0.9705248
Epsilon_f Epsilon_prime_f Sigma_prime_f
-0.4655494 -0.1202111  0.8964122
```

Prenons une variable ayant une corrélation faible mais aussi négative, soit  $\mathcal{E}_f$ .

```
> summary(lm(Sigma_prime_f~ Sigma_e+Epsilon_f, projet))
Call:
lm(formula = Sigma_prime_f ~ Sigma_e + Epsilon_f, data = projet)

Residuals:
    Min       1Q   Median       3Q      Max
-426.64 -136.79  -40.91   99.70  671.30

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  925.11499   108.07443    8.560  1.7e-12 ***
Sigma_e       0.83908    0.05752   14.588  < 2e-16 ***
Epsilon_f    -332.75903   97.10119   -3.427  0.00103 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 234.1 on 70 degrees of freedom
Multiple R-squared:  0.8318,    Adjusted R-squared:  0.827
F-statistic: 173.1 on 2 and 70 DF,  p-value: < 2.2e-16
```

L'amélioration est considérable (en ce qui concerne r1 et r2) donc cette régression multiple est potentiellement bonne. Or l'ajout d'une variable provoque une baisse de F-statistique.

### Test pour BHN

```
> mc [,2]
      E      BHN      RA      Sigma_e      Sigma_u
-0.3518188  1.0000000 -0.5075624  0.9644053  0.9800446
Epsilon_f Epsilon_prime_f Sigma_prime_f
-0.5388124 -0.1239751  0.9361995
```

Le test actuel manifeste de meilleurs résultats par rapport au précédent.

```
> summary(lm(Sigma_prime_f~ BHN, projet))

Call:
lm(formula = Sigma_prime_f ~ BHN, data = projet)

Residuals:
    Min       1Q   Median       3Q      Max
-361.51 -143.24  -16.89   98.31  645.10

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 249.9850    58.5694   4.268 5.99e-05 ***
BHN          4.0384     0.1799  22.445 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 199.2 on 71 degrees of freedom
Multiple R-squared:  0.8765,    Adjusted R-squared:  0.8747
F-statistic: 503.8 on 1 and 71 DF,  p-value: < 2.2e-16
```

La régression multiple n'apporte pas rien d'intéressant à notre model. Qu'allons nous avoir avec  $\Sigma'_u$

### Test pour $\Sigma'_u$

```
> summary(lm(Sigma_prime_f~ Sigma_u, projet))

Call:
lm(formula = Sigma_prime_f ~ Sigma_u, data = projet)

Residuals:
    Min       1Q   Median       3Q      Max
-322.72 -135.33  -11.60   92.76  565.55

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 353.0195    49.5474   7.125 6.93e-10 ***
Sigma_u      1.0023     0.0406  24.687 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 183.1 on 71 degrees of freedom
Multiple R-squared:  0.8957,    Adjusted R-squared:  0.8942
F-statistic: 609.5 on 1 and 71 DF,  p-value: < 2.2e-16
```

La régression simple avec  $\Sigma'_u$  est très pertinente mais qu'aurons nous avec une régression multiple avec une variable à faible corrélation avec  $\Sigma'_u$ , soit  $\mathcal{E}'_f$ .

```
> summary(lm(Sigma_prime_f~ Sigma_u+Epsilon_prime_f, projet))

Call:
lm(formula = Sigma_prime_f ~ Sigma_u + Epsilon_prime_f, data = projet)

Residuals:
    Min       1Q   Median       3Q      Max
-313.52 -124.05  -14.87  100.54  561.51

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 323.58816    63.31780   5.111 2.67e-06 ***
Sigma_u      1.00736     0.04128  24.404 < 2e-16 ***
Epsilon_prime_f 49.73131    66.28855   0.750  0.456
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 183.6 on 70 degrees of freedom
Multiple R-squared:  0.8965,    Adjusted R-squared:  0.8935
F-statistic: 303.1 on 2 and 70 DF,  p-value: < 2.2e-16
```

On voit bien qu'aucune amélioration n'a été portée.

## Le modèle élu

A l'issus de ces résultats, il est claire que la régression linéaire simple avec  $\Sigma_u$  est le modèle le plus adéquat pour une régression linéaire sur  $\Sigma'_f$ .

```
> regression = lm(Sigma_prime_f ~ Sigma_u, projet)
> regression

Call:
lm(formula = Sigma_prime_f ~ Sigma_u, data = projet)

Coefficients:
(Intercept)      Sigma_u
    353.019         1.002
```

La formule du model est la suivante :

$$\Sigma'_f = 1.002 \Sigma_u + 353.019$$

## Tests sur $\Sigma'_f$

```
> mc [,7]
      E      BHN      RA      Sigma_e      Sigma_u
0.002866055 -0.123975139  0.196220131 -0.120211063 -0.163169595
Epsilon_f Epsilon_prime_f Sigma_prime_f
0.162873180  1.000000000 -0.125959958
```

RA est la variable la plus corrélé avec  $\Sigma'_f$  donc la régression linéaire simple va être avec cette variable et on aura :

```
> summary(lm(Epsilon_prime_f~RA, projet))

Call:
lm(formula = Epsilon_prime_f ~ RA, data = projet)

Residuals:
    Min       1Q   Median       3Q      Max
-0.50623 -0.23024 -0.05425  0.16575  1.45575

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.286277   0.121088   2.364   0.0208 *
RA           0.003999   0.002372   1.686   0.0962 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3268 on 71 degrees of freedom
Multiple R-squared:  0.0385,    Adjusted R-squared:  0.02496
F-statistic: 2.843 on 1 and 71 DF,  p-value: 0.09616
```

## Conclusion

Une étude a été faite sur l'épuisement des matériaux (l'acier). Grâce à un outil puissant (**R**) et un model a été élu pour nos données.

## Remarques

La liste illustrée des résultats de lecture du fichier n'est pas exhaustive.

Epsilon\_prime\_f (le coefficient de ductilité en fatigue) est représenté par  $\epsilon'_f$ .

Sigma\_prime\_f (le coefficient de résistance en fatigue) est représenté par  $\sigma'_f$ .

Sigma\_e (contrainte ou charge initiale en traction) est représenté par  $\sigma_e$ .

Sigma\_u (contrainte ou charge à la rupture en traction) est représenté par  $\sigma_u$ .

Epsilon\_f (facteur de ductilité) est représenté par  $\epsilon_f$ .

BHN (dureté de brinell).

RA (coefficient de striction après rupture).